Práctica 1. Seguridad en los Sistemas Inteligentes (1 punto)

Para realizar en grupos de 3 personas.

Importante:

1. Obligatorio inscribirse en la actividad de formación de grupos a través del Campus Virtual antes del viernes 13 de marzo a las 23:59 horas.
2. Todos los integrantes del equipo deben estar familiarizados con la totalidad de los ejercicios de la práctica.
3. Es importante, especialmente en el ámbito de esta materia, aprender a seleccionar fuentes confiables y de calidad, así como contrastar la información encontrada, utilizando para ello varias fuentes. Por eso, en los ejercicios que se pida búsqueda de información es obligatorio contrastar la misma con al menos 2 fuentes relevantes y citar dichas fuentes en el texto. La calidad y relevancia de las fuentes bibliográficas utilizadas será determinante para la calificación. Las fuentes utilizadas se deben incluir al final de la memoria bajo el título de Referencias, en formato APA y en orden alfabético (por apellido del primer autor). En (Servicio de Biblioteca Universitaria, 2021) se puede consultar una breve guía sobre citas y referencias bibliográficas.
4. **IMPORTANTE:** No incluyáis en la memoria descripciones o conceptos que no comprendáis. Consultad cualquier duda con el profesor de prácticas.

Clasificación de ataques en AML (10 %)

1. **Búsqueda y clasificación de incidentes:** Seleccionad 4 noticias, artículos técnicos o reportes de incidentes documentados sobre ataques reales contra sistemas de Inteligencia Artificial, incluyendo 2 relativos a PredAI y 2 sobre GenAI.
    - Para cada uno de los incidentes, redactad un breve resumen de aproximadamente 300 palabras en el que se explique el vector de ataque y clasificadlo estrictamente según la taxonomía de AML `NIST AI 100-2e2025` (Vassilev, 2025).
    - Existe alguna vulnerabilidad relacionada con cada uno de los incidentes? Si es así, identificadlas y referenciad sus CVEs correspondientes.
    - Realizad una propuesta de mitigación para cada uno de los incidentes.
    - Los ataques identificados deben ser de diferente tipología y origen.

Ataques y defensas en PredAI (70 %)

2. **Ataques de evasión de caja blanca (white-box evasion):** Implementad y evaluad ataques adversarios de evasión sobre un modelo de clasificación de imágenes previamente entrenado.
    - Cargad el dataset CIFAR-10[1] y el modelo pre-entrenado ResNet-20[2].
    - Implementad manualmente el ataque *Fast Gradient Sign Method* (FGSM) para generar ejemplos adversarios sobre el subconjunto de test de CIFAR-10 de al menos 1000 imágenes.
    - Realizad el ataque iterativo *Projected Gradient Descent* (PGD) utilizando el framework de PyTorch Adversarial Robustness Toolbox (ART)[3].

[1] `https://www.cs.toronto.edu/~kriz/cifar.html`
[2] `https://github.com/chenyaofo/pytorch-cifar-models`
[3] `https://adversarial-robustness-toolbox.readthedocs.io/`

- Generad una gráfica comparativa que muestre la Tasa de Éxito del Ataque (ASR) frente al presupuesto de perturbación (ϵ) para ambos ataques, utilizando la norma L_∞ para acotar el ruido.
- Posteriormente, emplementad un método de defensa en inferencia (preprocesamiento) mediante una transformación de entrada (compresión JPEG o desenfoque Gaussiano) y aplícala a las imágenes adversarias generadas con FGSM y PGD. Medid y documentad en qué porcentaje se reduce la efectividad del ataque (ASR), y comprobad cómo afecta esta transformación a la precisión del modelo sobre imágenes limpias (CDA).
- Incluid en la memoria evidencias visuales mostrando ejemplos de imágenes originales, el ruido generado amplificado y la imagen perturbada resultante, junto con las predicciones del modelo.

3. **Envenenamiento de datos y troyanos (backdoors):** Vulnerad el proceso de entrenamiento de un modelo inyectando un comportamiento malicioso oculto.

   - Cread un dataset de entrenamiento envenenado seleccionando un 5 % de las imágenes de entrenamiento de CIFAR-10. Inyectad un *trigger* visual (ej. un parche amarillo de 3x3 píxeles en una esquina) y alterad forzosamente su etiqueta original a una clase objetivo específica.
   - Realizad un *fine-tuning* del modelo pre-entrenado ResNet-20 utilizando el dataset envenenado. Ajustad el número de épocas y el *learning rate* para optimizar el rendimiento del modelo.
   - Evaluad el modelo resultante calculando el *Clean Data Accuracy* (CDA) sobre el conjunto de test limpio, y el *Attack Success Rate* (ASR) sobre el conjunto de test completamente modificado con el *trigger*.
   - Estudio de ablación: Repetid el experimento variando el tamaño del parche (ej. 1x1, 3x3, 5x5) y documentad las variaciones de CDA y ASR en una tabla comparativa.

Seguridad en GenAI (20 %)

4. **Ataques sobre sistemas LLM:** Acceded a la plataforma de retos de IA del Centro Criptológico Nacional (CCN), **LABIA**[4]. Resolved la mayor cantidad de retos posibles dentro de la plataforma, orientados a vulnerar sistemas LLM.

   - Aportad en la memoria evidencias (explicaciones y capturas de pantalla) que demuestren de forma inequívoca la técnica utilizada para resolver el reto de cada nivel, el prompt utilizado, y la contraseña averiguada.
   - Si alguno de los ataques requiere de varios pasos o intercambio de mensajes, incluid en la explicación todo el proceso.
   - La nota de este ejercicio se calculará de forma proporcional al nivel máximo alcanzado por la clase. El grupo que llegue al nivel más alto obtendrá la máxima puntuación en este apartado, y el resto de grupos recibirán una calificación proporcional según su progreso.

[4] `https://labia.ccn.cni.es`

Entrega:

- Vía Campus Virtual (Moodle). Sólo una entrega por grupo. No más tarde de las **10:30 AM del lunes, 6 de abril de 2026**.
- Sólo se admiten los siguientes archivos:
  - **Memoria** (formato .pdf).
    - Extensión máxima 8000 palabras (la portada, índice y el apartado de referencias no cuentan).
    - Nombre: `<GN>_memoria.pdf`. Donde `<GN>` es el número de grupo[5].
      Por ejemplo: `2.3_memoria.pdf` para el grupo 2.3.
  - **Código fuente** (Jupyter Notebooks; formato .ipynb).
    - Un fichero Jupyter Notebook por cada ejercicio que requiera ejecución de código. Todos los resultados obtenidos deben ser incluidos en el notebook, y ser perfectamente reproducibles sin errores.
    - Nombre: `<GN>_codigo_<EjN>.ipynb`. Donde `<GN>` es el número de grupo[5] y `<EjN>` es el número de ejercicio.
      Por ejemplo: `2.3_codigo_2.ipynb` para el segundo ejercicio del grupo 2.3.

Defensa

Posteriormente a la entrega, el profesor indicará una fecha para la defensa de la práctica. En la defensa deben estar presentes todos los integrantes del grupo, cada uno con su ordenador y todo lo necesario para poder mostrar cualquier ejercicio de la práctica.

Durante la defensa, cualquiera de los miembros podrá ser requerido para explicar cualquier apartado, demostrar su ejecución o responder preguntas relacionadas.

Evaluación

La evaluación de cada apartado tendrá en cuenta tanto el documento de la memoria, como las respuestas y destreza mostradas en la defensa. Teniendo en cuenta que, si durante la defensa el grupo no es capaz de justificar el contenido que figura en la memoria, podría invalidar el apartado correspondiente.

Adicionalmente, se valorará positivamente la participación en clase, pudiendo suponer hasta un 15 % de puntuación adicional.

Referencias

Servicio de Biblioteca Universitaria. (2021). **Citas y referencias**. Universidade da Coruña. `https://infoguias.biblioteca.udc.es/citas_referencias_es`.

Vassilev, Apostol. (2025). **Adversarial Machine Learning: A Taxonomy and Terminology of Attacks and Mitigations**. `https://www.nist.gov/publications/adversarial-machine-learning-taxonomy-and-terminology-attacks-and-mitigations`.

[5] El listado de grupos oficial se publicará en Campus Virtual una vez finalice el plazo de inscripción de grupos.